RESULTADOS

Metrics

Valid Set | External

mAP@50 41.7% | Precision 65.2% | Recall 39.4%

Class	Images	Instances	Box(P	R	mAP50	mAP50-95):
all	22	282	0.654	0.395	0.417	0.29
gloves	1	1	0	0	0.00248	0.00149
harness	2	2	1	0	0.0148	0.00724
helmet	18	54	0.688	0.759	0.831	0.516
no_helmet	4	10	0.824	0.4	0.417	0.305
no_safety_shoe	4	12	0.49	0.5	0.474	0.373
no_safety_vest	5	8	1	0	0.0281	0.00858
person	22	77	0.67	0.805	0.819	0.655
safety_shoe	15	68	0.56	0.43	0.452	0.238
safety_vest	14	50	0.658	0.66	0.715	0.506

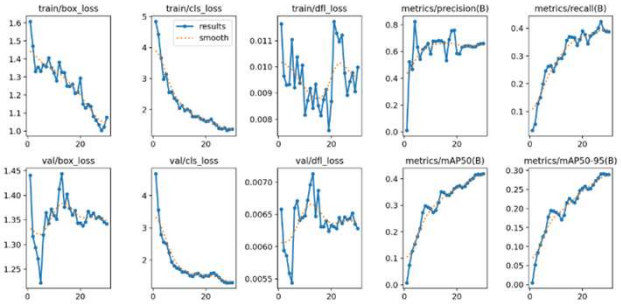

RESUMEN EJECUTIVO

Se desarrolló un modelo de detección de objetos basado en YOLO para identificar equipos de protección personal (EPP) en entornos de trabajo. El modelo fue entrenado con un dataset etiquetado que incluye clases como person, helmet, safety_vest, gloves, harness y welding_mask. El objetivo es detectar automáticamente el uso correcto o incorrecto de elementos de seguridad en imágenes de obra o entornos industriales.

Hallazgos

- El modelo muestra buen desempeño en las clases con mayor representación en el dataset, especialmente person, harness y safety_vest, lo que indica que aprende correctamente cuando dispone de suficientes ejemplos durante el entrenamiento.
- Sin embargo, se observan dificultades en clases minoritarias como gloves, no_safety_vest y welding_mask.
- El análisis de la matriz de confusión revela que welding_mask se confunde frecuentemente con otras clases como helmet o person, mientras que gloves y no_safety_vest presentan varios falsos negativos, probablemente debido al tamaño reducido de los objetos o a la baja cantidad de ejemplos en el dataset.
- En general, el modelo logra detectar los principales elementos de seguridad, pero su rendimiento disminuye en clases poco representadas o visualmente similares.

Limitaciones

- La principal limitación del modelo es el desbalance del dataset, donde clases como person o harness tienen muchos más ejemplos que gloves, no_safety_vest o welding_mask, generando un sesgo en el entrenamiento.
- Además, existe similitud visual entre algunas clases, especialmente entre helmet y welding_mask, lo que provoca confusiones en la predicción. Finalmente, objetos pequeños como los guantes son más difíciles de detectar, y en algunos casos el modelo interpreta instancias reales como fondo (background), generando falsos negativos.

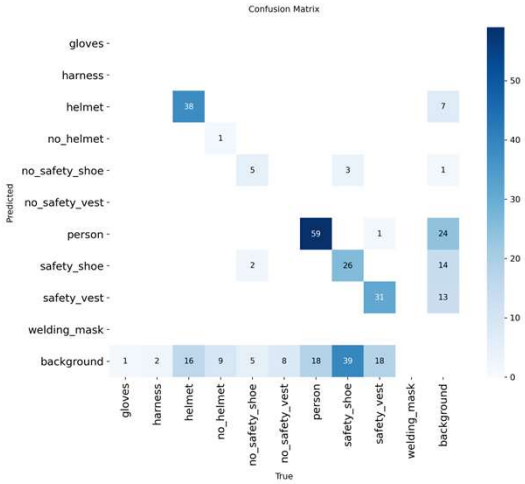

CONCLUSIONES

- Los resultados obtenidos indican que el modelo no alcanza un desempeño satisfactorio según las métricas de evaluación. Aunque logra detectar correctamente algunas clases dominantes como **person**, **harness** y **safety_vest**, presenta un rendimiento bajo en clases minoritarias como **gloves**, **no_safety_vest** y **welding_mask**.
- Esto sugiere que el modelo está afectado por el desbalance del dataset y por la similitud visual entre ciertas clases. En consecuencia, se requieren mejoras en la cantidad y calidad de los datos de entrenamiento para lograr un modelo más robusto y fiable.