ZIGURAT Institute of Technology

MASTER EN INTELIGENCIA ARTIFICAL PARA ARQUITECTURA Y CONSTRUCCIÓN

ASIGNATURA:	**MAIC-1125-M4T3 |** Programación e Inteligencia Artificial para el Sector AECO **| Visión Computacional**
TAREA:	**PROTOTIPO AECO CV + REPOSITORIO REPRODUCIBLE (SOLO NUBE)**
FECHA:	8 de marzo, 2026
DOCENTE:	Pablo Aumente
PREPARADO POR:	Dora Vaca

ALCANCE:

Repositorio en GitHub que un tercero pueda abrir en el navegador y reproducir los resultados en Google Colab sin instalaciones locales.
El repositorio incluye: planteamiento del problema, referencia del dataset, salidas de entrenamiento (métricas + curvas), evidencias de inferencia (validación + imágenes nuevas), análisis de errores y notas de gobernanza/licencias.

CASO DE USO

Objetivo: Detectar objetos/clases en imágenes de contexto AECO:
Equipo de Seguridad Personal en Obras, incluyendo:

- Guantes
- Arnés
- Cascos
- Zapatos de seguridad
- Chaleco de seguridad
- Personas
- Máscaras para soldadores

Éxito

=

- obtener mAP ≥ 0.5 en validación
- resultados consistentes en imágenes nuevas.

PROTOTIPO DEL MODELO

DATASET
(Roboflow)

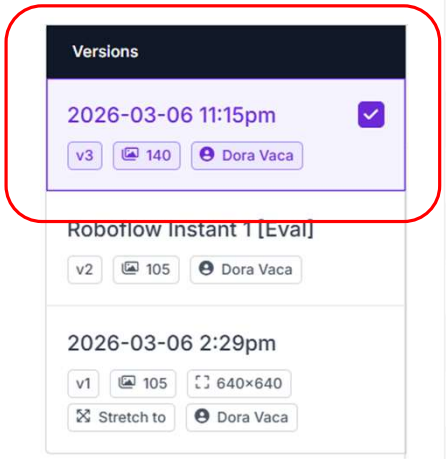

COLOR	CLASS NAME	COUNT
	gloves	45
	harness	27
	helmet	284
	no_helmet	60
	no_safety_shoe	99
	no_safety_vest	41
	person	429
	safety_shoe	210
	safety_vest	237
	welding_mask	9

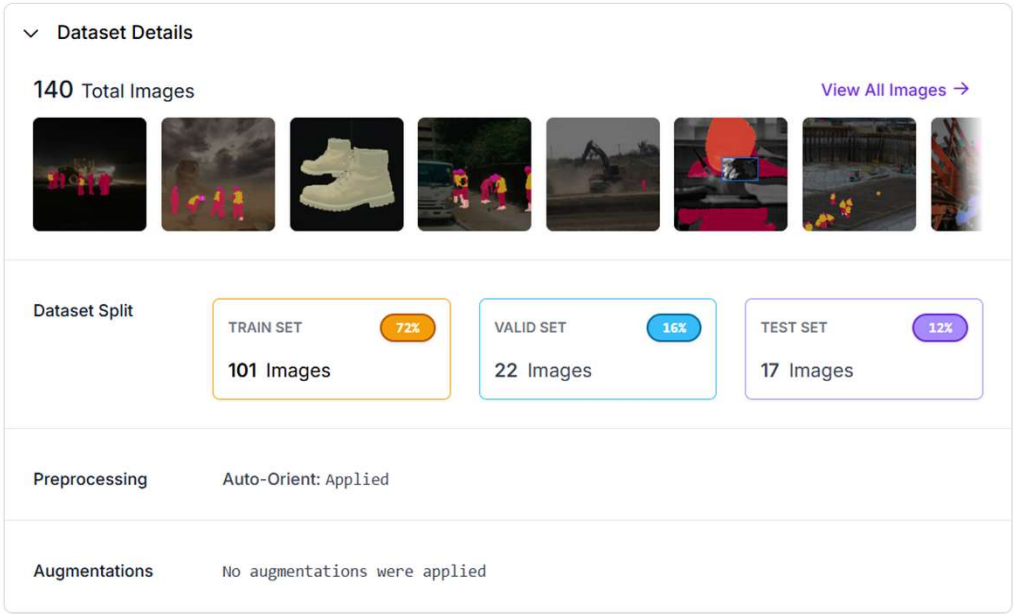

Prototipo del Modelo

INFERENCIA BASE
(Colab –COCO)

Inferencia base con modelo preentrenado en COCO para demostrar que el modelo detecta objetos antes de entrenarlo.)

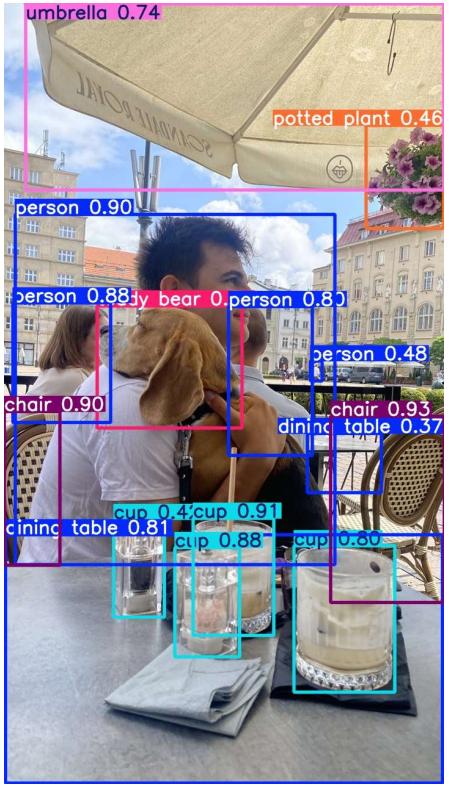

ENTRENAMIENTO
(Colab –YOLO26)

Entrenamiento del modelo con dataset exportado desde Roboflow:

- Durante 30 épocas
- Tamaño de imagen 640x640

EVALUACIÓN DEL MODELO
(Colab –YOLO26)

Metrics

Valid Set		External
mAP@50	Precision	Recall
41.7%	65.2%	39.4%

```
!yolo task=detect mode=val model={HOME}/runs/detect/train/weights/best.pt data={dataset.location}/data.yaml

Ultralytics 8.4.21 🚀 Python-3.12.12 torch-2.10.0+cu128 CUDA:0 (Tesla T4, 14913MiB)
YOLO26m summary (fused): 132 layers, 20,357,162 parameters, 0 gradients, 67.9 GFLOPs
val: Fast image access ✅ (ping: 0.0±0.0 ms, read: 2709.9±938.0 MB/s, size: 1511.6 KB)
val: Scanning /content/datasets/M4T3_TAREA_DORA_VACA-3/valid/labels.cache... 22 images, 0 backgrounds, 0 corrupt: 100% ━━━━━━━━━━━━ 22/22 3.5Mit/s 0.0s
val: /content/datasets/M4T3_TAREA_DORA_VACA-3/valid/images/ahmet-kurt-znZ-Pjy_tpE-unsplash_jpg.rf.3980495454a7fedc8535bd5db898a5a1.jpg: 1 duplicate labels removed
                 Class     Images  Instances      Box(P          R      mAP50  mAP50-95): 100% ━━━━━━━━━━━━ 2/2 1.5s/it 2.9s
                   all         22        282      0.654      0.395      0.417       0.29
                gloves          1          1          0          0    0.00248    0.00149
               harness          2          2          1          0     0.0148    0.00724
                helmet         18         54      0.688      0.759      0.831      0.516
             no_helmet          4         10      0.824        0.4      0.417      0.305
        no_safety_shoe          4         12       0.49        0.5      0.474      0.373
        no_safety_vest          5          8          1          0     0.0281    0.00858
                person         22         77       0.67      0.805      0.819      0.655
           safety_shoe         15         68       0.56       0.43      0.452      0.238
           safety_vest         14         50      0.658       0.66      0.715      0.506
Speed: 8.1ms preprocess, 38.6ms inference, 0.0ms loss, 0.3ms postprocess per image
Results saved to /content/runs/detect/val2
💡 Learn more at https://docs.ultralytics.com/modes/val
```

COLOR	CLASS NAME	COUNT
	gloves	45
	harness	27
	helmet	284
	no_helmet	60
	no_safety_shoe	99
	no_safety_vest	41
	person	429
	safety_shoe	210
	safety_vest	237
	welding_mask	9

Hallazgos por clase:

No logra detectar guantes (dataset insuficiente).

Detecta muy poco, dataset demasiado pequeño.

Muy buen desempeño, detecta cascos con alta precisión y recall.

Alta precisión pero bajo recall: detecta pocos casos, aunque los que detecta son correctos.

Moderado, reconoce la mitad de los casos.

Dataset insuficiente.

Excelente detección de personas, consistente.

Regular, necesita más ejemplos o mejor anotación.

Buen desempeño, bastante equilibrado.

No detectada.

- **Precisión (P): 0.654** → De las predicciones positivas, ~65% fueron correctas.
- **Recall (R): 0.395** → El modelo detectó ~39% de los objetos reales.
- **mAP50: 0.417** → Exactitud promedio al 50% IoU.
- **mAP50-95: 0.29** → Exactitud promedio más estricta (IoU 50–95).

En general, el modelo reconoce objetos, pero aún pierde bastantes instancias (recall bajo).

Solución: ampliar dataset.

NOTA: El dataset fue ampliado en dos ocasiones previamente.

EVALUACIÓN DEL MODELO
(Colab –YOLO26)

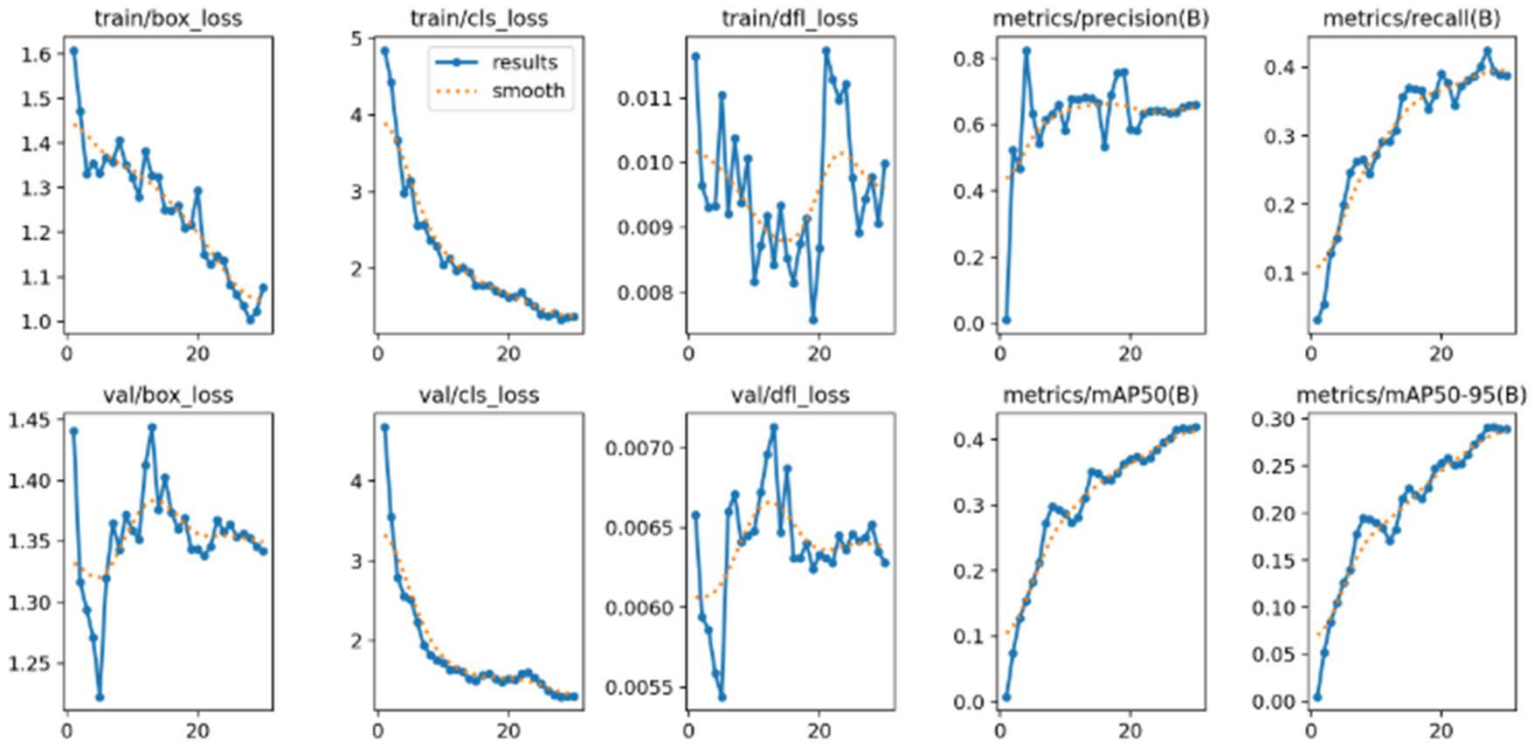

- **train/box_los:** La pérdida de cajas disminuye de forma consistente. El modelo está aprendiendo a ubicar mejor los objetos en las imágenes.
- **train/cls_los:** La pérdida de clasificación también baja, lo que indica que el modelo mejora en asignar la clase correcta.
- **train/dfl_los:** Más fluctuante, pero con tendencia a estabilizarse. Esto refleja el ajuste fino de las distribuciones de los bordes de las cajas.
- **metrics/precision(B):** La precisión sube con altibajos. El modelo cada vez comete menos falsos positivos, aunque aún hay variabilidad.
- **metrics/recall(B):** El recall aumenta con las épocas, el modelo detecta más objetos reales conforme avanza el entrenamiento.

EVALUACIÓN DEL MODELO
(Colab –YOLO26)

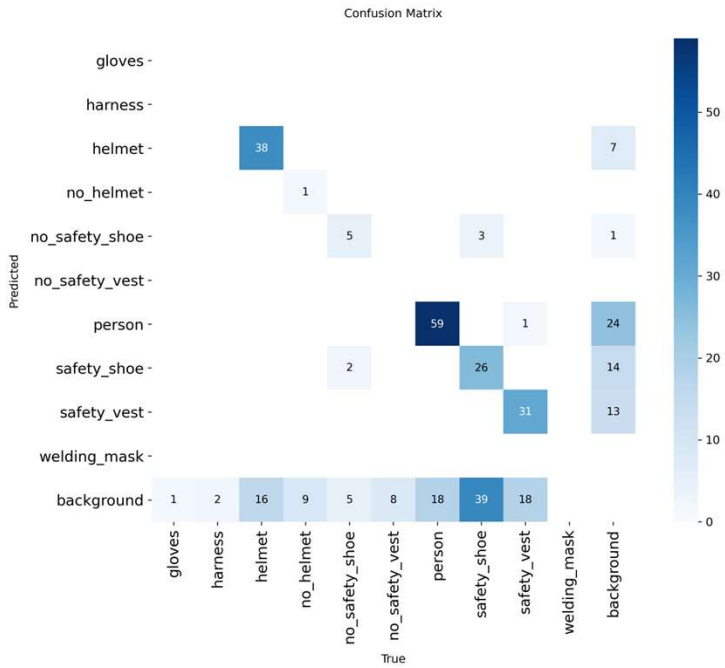

Conclusiones

- El modelo funciona bien en clases dominantes (person, harness, safety_vest).
- Problemas graves en clases minoritarias (gloves, no_safety_vest, welding_mask).
- Tendencia a confundir con background: muchas instancias reales se pierden porque el modelo las interpreta como fondo.
- Welding mask es la clase más confusa: se mezcla con casco, persona, zapatos y chaleco.

Recomendaciones

- Aumentar dataset en clases débiles (guantes, sin chaleco, sin zapato, careta de soldadura).
- Mejorar anotaciones: revisar etiquetas de welding_mask y helmet, que parecen solaparse.
- Balancear clases: reducir el sesgo hacia person y harness, que tienen más ejemplos.
- Data augmentation específico: aplicar recortes, rotaciones y variaciones de iluminación para clases minoritarias.
- Separar visualmente clases similares: por ejemplo, diferenciar mejor helmet vs welding_mask en anotaciones y dataset.

Prototipo del Modelo

VALIDACIÓN DEL MODELO
(Colab –YOLO26)

Carga del modelo entrenado y visualización de detecciones.

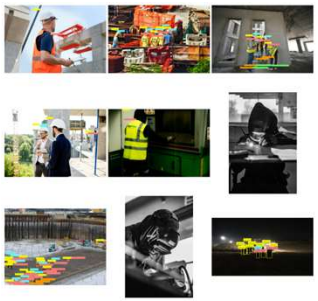

INFERENCIA MODELO DESPLEGADO
(Colab)

Usar el modelo que ya está desplegado en la nube de Roboflow para realizar predicciones sobre nuevas imágenes o datos.

EVALUACIÓN CON IMÁGENES PROPIAS
(Colab)

Evaluar el modelo realizando predicciones sobre imágenes propias.

Prototipo del Modelo

GOBERNANZA
(GitHUB)

Checklist de Gobernanza
- Privacidad y consentimiento
- Minimización de datos
- Declaración de limitaciones
- Nota de riesgos (FN vs FP)
- Licencia
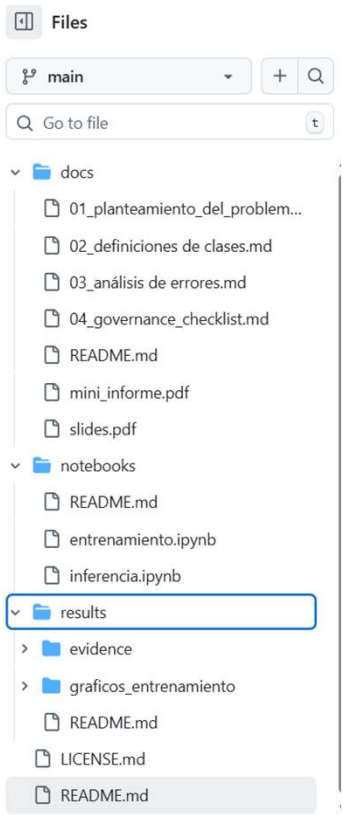
ESTRUCTURA
(GitHUB)